

Обучение с подкреплением

Актуальные подходы и проблемы

Леонтьев Михаил

ML-researcher

НИУ ВШЭ, X5 Tech

Содержание

- 1 Введение в RL
- 2 Policy Gradient Critic
- 3 Proximal Policy Optimization
- 4 RLHF
- 5 RLVR
- 6 RLVR Interpretability

Введение в RL

Обучение с подкреплением

Представьте, что вам нужно научиться
(=написать алгоритм) для игры в Марио.
У вас есть: приставка с этой игрой
и В С Ё.


Как быть?



Цикл взаимодействия

В каждый момент времени t :


- Наша среда находится в состоянии (state) s_t



Цикл взаимодействия

В каждый момент времени t :


- Наша среда находится в состоянии (state) s_t
- Мы можем сделать действие (action) a_t



Цикл взаимодействия

В каждый момент времени t :


- Наша среда находится в состоянии (state) s_t
- Мы можем сделать действие (action) a_t
- За это действие мы получаем награду (reward) r_t (в зависимости только от s_t, a_t)



Цикл взаимодействия

В каждый момент времени t :

- Наша среда находится в состоянии (state) s_t
- Мы можем сделать действие (action) a_t
- За это действие мы получаем награду (reward) r_t (в зависимости только от s_t, a_t)
- После этого игра переходит в состояние s_{t+1} (в зависимости только от s_t, a_t)




Цикл взаимодействия

В каждый момент времени t :

- Наша среда находится в состоянии (state) s_t
- Мы можем сделать действие (action) a_t
- За это действие мы получаем награду (reward) r_t (в зависимости только от s_t, a_t)
- После этого игра переходит в состояние s_{t+1} (в зависимости только от s_t, a_t)

Есть ли в этой схеме какие-то допущения?




Цикл взаимодействия

В каждый момент времени t :

- Наша среда находится в состоянии (state) s_t
- Мы можем сделать действие (action) a_t
- За это действие мы получаем награду (reward) r_t (в зависимости **ТОЛЬКО** от s_t, a_t)
- После этого игра переходит в состояние s_{t+1} (в зависимости **ТОЛЬКО** от s_t, a_t)


Есть ли в этой схеме какие-то допущения?

Марковское свойство



Policy

«Игроком» в данном случае является $\pi(a_t|s_t)$ (**policy**) — вероятностное распределение действий a_t .



Policy Gradient and Critic

Policy-based


Пусть π_θ — какая-то *модель машинного обучения* с параметрами θ , которая по состоянию s_t выдаёт вероятности действия $\pi_\theta(a_t|s_t)$.

Что оцениваем

Пусть мы сыграли один раз, получив траекторию $\tau = (s_t, r_t, a_t)_{t \geq 0}$. Оценим её так:

$$R(\tau) = \sum_{t=0}^{+\infty} \gamma^t r_t$$

, где $\gamma \in [0, 1]$ — коэффициент дисконтирования (**discounting**).



Exploration vs. Exploitation




Какая стратегия здесь оптимальна?

Что оцениваем

Пусть мы сыграли один раз, получив траекторию $\tau = (s_t, r_t, a_t)_{t \geq 0}$. Оценим её так:

$$R(\tau) = \sum_{t=0}^{+\infty} \gamma^t r_t$$

, где $\gamma \in [0, 1]$ — коэффициент дисконтирования (**discounting**).



Тогда как оценить «успешность» нашей π_θ ?


Что оцениваем

Пусть мы сыграли один раз, получив траекторию $\tau = (s_t, r_t, a_t)_{t \geq 0}$. Оценим её так:

$$\mathcal{J}(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} [R(\tau)] = \mathbb{E}_{\tau \sim \pi_\theta} \sum_{t=0}^{+\infty} \gamma^t r_t$$

, где $\gamma \in [0, 1]$ — коэффициент дисконтирования (**discounting**).

Тогда как оценить «успешность» нашей π_θ ?



Loss Function

Мы хотим максимизировать $\mathcal{J}(\theta)$ по всем θ . Можем использовать *град. подъем* для этого. Но тогда нужно уметь считать $\nabla_{\theta} \mathcal{J}$.

$$\mathcal{J}(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}}[R(\tau)] = \sum_{\tau} \mathbb{P}(\tau) \cdot R(\tau)$$

Однако считать $\mathbb{P}(\tau)$ может быть сложно считать. *Что делать?*



Loss Function

Мы хотим максимизировать $\mathcal{J}(\theta)$ по всем θ . Можем использовать *град. подъем* для этого. Но тогда нужно уметь считать $\nabla_{\theta} \mathcal{J}$.

$$\mathcal{J}(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}}[R(\tau)] = \sum_{\tau} \mathbb{P}(\tau) \cdot R(\tau)$$

Однако считать $\mathbb{P}(\tau)$ может быть сложно считать. *Что делать?*

Policy Gradient Theorem

$$\nabla_{\theta} \mathcal{J} = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=1}^{|\tau|} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot R(\tau) \right]$$



Policy Gradient Theorem: доказательство

Policy Gradient Theorem

$$\nabla_{\theta} \mathcal{J} = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=1}^{|\tau|} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot R(\tau) \right]$$

$$\nabla_{\theta} \mathcal{J} =$$

Policy Gradient Theorem: доказательство

Policy Gradient Theorem

$$\nabla_{\theta} \mathcal{J} = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=1}^{|\tau|} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot R(\tau) \right]$$

$$\nabla_{\theta} \mathcal{J} = \nabla_{\theta} \sum_{\tau} \mathbb{P}(\tau | \theta) R(\tau)$$

Policy Gradient Theorem: доказательство

Policy Gradient Theorem

$$\nabla_{\theta} \mathcal{J} = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=1}^{|\tau|} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot R(\tau) \right]$$

$$\nabla_{\theta} \mathcal{J} = \nabla_{\theta} \sum_{\tau} \mathbb{P}(\tau | \theta) R(\tau) = \sum_{\tau} R(\tau) \nabla_{\theta} \mathbb{P}(\tau | \theta)$$

Policy Gradient Theorem: доказательство

Policy Gradient Theorem

$$\nabla_{\theta} \mathcal{J} = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=1}^{|\tau|} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot R(\tau) \right]$$

$$\nabla_{\theta} \mathcal{J} = \nabla_{\theta} \sum_{\tau} \mathbb{P}(\tau | \theta) R(\tau) = \sum_{\tau} R(\tau) \nabla_{\theta} \mathbb{P}(\tau | \theta) = \sum_{\tau} R(\tau) \mathbb{P}(\tau | \theta) \frac{\nabla_{\theta} \mathbb{P}(\tau | \theta)}{\mathbb{P}(\tau | \theta)}$$

Policy Gradient Theorem: доказательство

Policy Gradient Theorem

$$\nabla_{\theta} \mathcal{J} = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=1}^{|\tau|} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot R(\tau) \right]$$

$$\nabla_{\theta} \mathcal{J} = \nabla_{\theta} \sum_{\tau} \mathbb{P}(\tau | \theta) R(\tau) = \sum_{\tau} R(\tau) \nabla_{\theta} \mathbb{P}(\tau | \theta) = \sum_{\tau} R(\tau) \mathbb{P}(\tau | \theta) \underbrace{\frac{\nabla_{\theta} \mathbb{P}(\tau | \theta)}{\mathbb{P}(\tau | \theta)}}_{\nabla_{\theta} \log \mathbb{P}(\tau | \theta)}$$

Policy Gradient Theorem: доказательство

Policy Gradient Theorem

$$\nabla_{\theta} \mathcal{J} = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=1}^{|\tau|} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot R(\tau) \right]$$

$$\nabla_{\theta} \mathcal{J} = \nabla_{\theta} \sum_{\tau} \mathbb{P}(\tau | \theta) R(\tau) = \sum_{\tau} R(\tau) \nabla_{\theta} \mathbb{P}(\tau | \theta) = \sum_{\tau} R(\tau) \mathbb{P}(\tau | \theta) \underbrace{\frac{\nabla_{\theta} \mathbb{P}(\tau | \theta)}{\mathbb{P}(\tau | \theta)}}_{\nabla_{\theta} \log \mathbb{P}(\tau | \theta)}$$

Итого, $\nabla_{\theta} \mathcal{J} = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \mathbb{P}(\tau | \theta) \cdot R(\tau)]$. Также заметим, что

$$\nabla_{\theta} \log \mathbb{P}(\tau | \theta) =$$

Policy Gradient Theorem: доказательство

Policy Gradient Theorem

$$\nabla_{\theta} \mathcal{J} = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=1}^{|\tau|} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot R(\tau) \right]$$

$$\nabla_{\theta} \mathcal{J} = \nabla_{\theta} \sum_{\tau} \mathbb{P}(\tau | \theta) R(\tau) = \sum_{\tau} R(\tau) \nabla_{\theta} \mathbb{P}(\tau | \theta) = \sum_{\tau} R(\tau) \mathbb{P}(\tau | \theta) \underbrace{\frac{\nabla_{\theta} \mathbb{P}(\tau | \theta)}{\mathbb{P}(\tau | \theta)}}_{\nabla_{\theta} \log \mathbb{P}(\tau | \theta)}$$

Итого, $\nabla_{\theta} \mathcal{J} = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \mathbb{P}(\tau | \theta) \cdot R(\tau)]$. Также заметим, что

$$\nabla_{\theta} \log \mathbb{P}(\tau | \theta) = \nabla_{\theta} \log \mathbb{P}(s_0) \prod_{t=1}^{|\tau|} \mathbb{P}(s_{t+1} | s_t, a_t) \pi_{\theta}(a_t | s_t)$$

Policy Gradient Theorem: доказательство

Policy Gradient Theorem

$$\nabla_{\theta} \mathcal{J} = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=1}^{|\tau|} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot R(\tau) \right]$$

$$\nabla_{\theta} \mathcal{J} = \nabla_{\theta} \sum_{\tau} \mathbb{P}(\tau | \theta) R(\tau) = \sum_{\tau} R(\tau) \nabla_{\theta} \mathbb{P}(\tau | \theta) = \sum_{\tau} R(\tau) \mathbb{P}(\tau | \theta) \underbrace{\frac{\nabla_{\theta} \mathbb{P}(\tau | \theta)}{\mathbb{P}(\tau | \theta)}}_{\nabla_{\theta} \log \mathbb{P}(\tau | \theta)}$$

Итого, $\nabla_{\theta} \mathcal{J} = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \mathbb{P}(\tau | \theta) \cdot R(\tau)]$. Также заметим, что

$$\nabla_{\theta} \log \mathbb{P}(\tau | \theta) = \nabla_{\theta} \log \mathbb{P}(s_0) \prod_{t=1}^{|\tau|} \mathbb{P}(s_{t+1} | s_t, a_t) \pi_{\theta}(a_t | s_t) = \sum_{t=1}^{|\tau|} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t)$$

REINFORCE

Алгоритм REINFORCE (или Monte-Carlo Reinforce):

- 1 Запустить N проходов для нашей $\pi_{\theta(k)}$

REINFORCE

Алгоритм **REINFORCE** (или Monte-Carlo Reinforce):

- 1 Запустить N проходов для нашей $\pi_{\theta(k)}$
- 2 Для каждой из получившихся траекторий τ_j посчитать

$$\hat{g}_j = \sum_{t=1}^{|\tau_j|} \nabla_{\theta} \log \pi_{\theta(k)}(a_t^{(j)} | s_t^{(j)}) \cdot R(\tau_j)$$

REINFORCE

Алгоритм **REINFORCE** (или Monte-Carlo Reinforce):

- 1 Запустить N проходов для нашей $\pi_{\theta^{(k)}}$
- 2 Для каждой из получившихся траекторий τ_j посчитать

$$\hat{g}_j = \sum_{t=1}^{|\tau_j|} \nabla_{\theta} \log \pi_{\theta^{(k)}}(a_t^{(j)} | s_t^{(j)}) \cdot R(\tau_j)$$

- 3 Тогда посчитаем $\nabla_{\theta} J(\theta^{(k)}) = \frac{1}{N} \sum_{j=1}^N \hat{g}_j$

REINFORCE

Алгоритм **REINFORCE** (или Monte-Carlo Reinforce):

- 1 Запустить N проходов для нашей $\pi_{\theta^{(k)}}$
- 2 Для каждой из получившихся траекторий τ_j посчитать

$$\hat{g}_j = \sum_{t=1}^{|\tau_j|} \nabla_{\theta} \log \pi_{\theta^{(k)}}(a_t^{(j)} | s_t^{(j)}) \cdot R(\tau_j)$$

- 3 Тогда посчитаем $\nabla_{\theta} J(\theta^{(k)}) = \frac{1}{N} \sum_{j=1}^N \hat{g}_j$
- 4 Обновляем полиси $\theta^{(k+1)} = \theta^{(k)} + \alpha \nabla_{\theta} J(\theta^{(k)})$

Value function

Проблема: $R(\tau)$ оценивает не только успешность нашей полиси, но и насколько удачны состояния, которые он посещает.

Value function


Проблема: $R(\tau)$ оценивает не только успешность нашей полиси, но и насколько удачны состояния, которые он посещает.

$$V^\pi(s) = \mathbb{E}_\pi \left[\underbrace{r_1 + \gamma r_2 + \gamma^2 r_3 + \dots}_{R(\tau)} \mid s_0 = s \right]$$

, то есть эта функция показывает, насколько удачно для нашей полиси π состояние s .


Critic model

Давайте вместе со стратегией π_θ обучать ещё и V_φ (то есть научимся понимать, насколько хороший reward мы умеем получать из такого состояния).



Critic model

Давайте вместе со стратегией π_θ обучать ещё и V_ϕ (то есть научимся понимать, насколько хороший reward мы умеем получать из такого состояния). *Как теперь можно улучшить подсчёт reward?*




Critic model

Давайте вместе со стратегией π_θ обучать ещё и V_φ (то есть научимся понимать, насколько хороший reward мы умеем получать из такого состояния). *Как теперь можно улучшить подсчёт reward?*

Введем функцию **advantage** (преимущества):

$$A_t(\tau) = R_t(\tau) - V_\varphi(s_t)$$




Critic model

Давайте вместе со стратегией π_θ обучать ещё и V_φ (то есть научимся понимать, насколько хороший reward мы умеем получать из такого состояния). *Как теперь можно улучшить подсчёт reward?*

Введем функцию **advantage** (преимущества):

$$A_t(\tau) = R_t(\tau) - V_\varphi(s_t)$$

Но нам уже не хочется считать $R_t(\tau)$. *Что делать?*



Generalized Advantage Estimation (GAE)

Заметим, что

$$R_t(\tau) = r_t + \gamma R_{t+1}(\tau) v_{\varphi}(s_{t+1})$$

Generalized Advantage Estimation (GAE)

Заметим, что

$$R_t(\tau) = r_t + \gamma R_{t+1}(\tau) V_\varphi(s_{t+1})$$

Тогда обозначим $\delta_t := r_t + \gamma V_\varphi(s_{t+1}) - V_\varphi(s_t)$ — получили оценку на A_t .

Generalized Advantage Estimation (GAE)

Заметим, что

$$R_t(\tau) = r_t + \gamma R_{t+1}(\tau) V_{\varphi}(s_{t+1})$$

Тогда обозначим $\delta_t := r_t + \gamma V_{\varphi}(s_{t+1}) - V_{\varphi}(s_t)$ — получили оценку на A_t .
Расширим эту идею: пусть имеем гиперпараметр $\lambda \in [0, 1]$. Тогда

$$\hat{A}_t := \sum_{k=0}^{|\tau|} (\gamma\lambda)^k \delta_{t+k}$$

Что будет, если $\lambda = 0$? $\lambda = 1$? $\lambda \in (0, 1)$?

Generalized Advantage Estimation (GAE)

Заметим, что

$$R_t(\tau) = r_t + \gamma R_{t+1}(\tau) V_\varphi(s_{t+1})$$

Тогда обозначим $\delta_t := r_t + \gamma V_\varphi(s_{t+1}) - V_\varphi(s_t)$ — получили оценку на A_t .
Расширим эту идею: пусть имеем гиперпараметр $\lambda \in [0, 1]$. Тогда

$$\hat{A}_t := \sum_{k=0}^{|\tau|} (\gamma\lambda)^k \delta_{t+k}$$

Что будет, если $\lambda = 0$? $\lambda = 1$? $\lambda \in (0, 1)$?

$$\lambda = 0 : \quad \hat{A}_t = \delta_t = r_t + \gamma V_\varphi(s_{t+1}) - V_\varphi(s_t)$$

Generalized Advantage Estimation (GAE)

Заметим, что

$$R_t(\tau) = r_t + \gamma R_{t+1}(\tau) V_\varphi(s_{t+1})$$

Тогда обозначим $\delta_t := r_t + \gamma V_\varphi(s_{t+1}) - V_\varphi(s_t)$ — получили оценку на A_t .
Расширим эту идею: пусть имеем гиперпараметр $\lambda \in [0, 1]$. Тогда

$$\hat{A}_t := \sum_{k=0}^{|\tau|} (\gamma\lambda)^k \delta_{t+k}$$

Что будет, если $\lambda = 0$? $\lambda = 1$? $\lambda \in (0, 1)$?

$$\lambda = 0 : \quad \hat{A}_t = \delta_t = r_t + \gamma V_\varphi(s_{t+1}) - V_\varphi(s_t)$$

$$\lambda = 1 : \quad \hat{A}_t = \sum_{k=0}^{|\tau|} \gamma^k \delta_{t+k} = R_t(\tau) - V_\varphi(s_t)$$

Generalized Advantage Estimation (GAE)

Заметим, что

$$R_t(\tau) = r_t + \gamma R_{t+1}(\tau) V_{\varphi}(s_{t+1})$$

Тогда обозначим $\delta_t := r_t + \gamma V_{\varphi}(s_{t+1}) - V_{\varphi}(s_t)$ — получили оценку на A_t .
Расширим эту идею: пусть имеем гиперпараметр $\lambda \in [0, 1]$. Тогда

$$\hat{A}_t := \sum_{k=0}^{|\tau|} (\gamma \lambda)^k \delta_{t+k}$$

Что будет, если $\lambda = 0$? $\lambda = 1$? $\lambda \in (0, 1)$? (обычно берут $\lambda \approx 0.95$)

$$\lambda = 0 : \quad \hat{A}_t = \delta_t = r_t + \gamma V_{\varphi}(s_{t+1}) - V_{\varphi}(s_t)$$

$$\lambda = 1 : \quad \hat{A}_t = \sum_{k=0}^{|\tau|} \gamma^k \delta_{t+k} = R_t(\tau) - V_{\varphi}(s_t)$$

Proximal Policy Optimization

Ratio Function

А что если использовать данные от **старой** политики $\pi_{\theta^{(k)}}$, чтобы оценить новую π_{θ} ?

Ratio Function

А что если использовать данные от **старой** политики $\pi_{\theta^{(k)}}$, чтобы оценить новую π_{θ} ?

$$r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta^{(k)}}(a_t|s_t)}$$

Ratio Function

А что если использовать данные от **старой** политики $\pi_{\theta^{(k)}}$, чтобы оценить новую π_{θ} ?

$$r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta^{(k)}}(a_t|s_t)}$$

- $r_t > 1$ — новая политика делает это действие *чаще*

Ratio Function

А что если использовать данные от **старой** политики $\pi_{\theta^{(k)}}$, чтобы оценить новую π_{θ} ?

$$r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta^{(k)}}(a_t|s_t)}$$

- $r_t > 1$ — новая политика делает это действие *чаще*
- $r_t < 1$ — новая политика делает это действие *реже*

Ratio Function

А что если использовать данные от **старой** политики $\pi_{\theta^{(k)}}$, чтобы оценить новую π_{θ} ?

$$r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta^{(k)}}(a_t|s_t)}$$

- $r_t > 1$ — новая политика делает это действие *чаще*
- $r_t < 1$ — новая политика делает это действие *реже*
- $r_t = 1$ — политики совпадают в этой точке

Ratio Function

А что если использовать данные от **старой** политики $\pi_{\theta^{(k)}}$, чтобы оценить новую π_{θ} ?

$$r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta^{(k)}}(a_t|s_t)}$$

- $r_t > 1$ — новая политика делает это действие *чаще*
- $r_t < 1$ — новая политика делает это действие *реже*
- $r_t = 1$ — политики совпадают в этой точке

Тогда будем оптимизировать:

$$\mathcal{L}^{CPI}(\theta) = \mathbb{E} \left[r_t(\theta) \cdot \hat{A}_t \right]$$

Ratio Function

Проблема: без ограничений $r_t(\theta)$ может стать очень большим.



Ratio Function

Проблема: без ограничений $r_t(\theta)$ может стать очень большим.

Если действие оказалось удачным ($\hat{A}_t > 0$) — алгоритм захочет резко увеличить его вероятность, $r_t \gg 1$.

Получаем слишком большой шаг.



Ratio Function

Проблема: без ограничений $r_t(\theta)$ может стать очень большим.

Если действие оказалось удачным ($\hat{A}_t > 0$) — алгоритм захочет резко увеличить его вероятность, $r_t \gg 1$.

Получаем слишком большой шаг. *Что делать?*



PPO-Clip

Идея PPO: просто **обрежем** $r_t(\theta)$ — не дадим ему уходить далеко от 1:

$$\mathcal{L}^{\text{CLIP}}(\theta) = \mathbb{E} \left[\min \left\{ r_t(\theta) \cdot \hat{A}_t, \text{clip}(r_t(\theta); 1-\varepsilon, 1+\varepsilon) \cdot \hat{A}_t \right\} \right]$$

где ε — гиперпараметр (обычно 0.1–0.2).

PPO-Clip

Идея PPO: просто **обрежем** $r_t(\theta)$ — не дадим ему уходить далеко от 1:

$$\mathcal{L}^{\text{CLIP}}(\theta) = \mathbb{E} \left[\min \left\{ r_t(\theta) \cdot \hat{A}_t, \text{clip}(r_t(\theta); 1-\varepsilon, 1+\varepsilon) \cdot \hat{A}_t \right\} \right]$$

где ε — гиперпараметр (обычно 0.1–0.2).

Разберём два случая:

- $A_t > 0$: действие хорошее, хотим увеличить r_t . Если $r_t > 1 + \varepsilon$ — $\min$ выбирает clip , градиент **обнуляется**.

PPO-Clip

Идея PPO: просто **обрежем** $r_t(\theta)$ — не дадим ему уходить далеко от 1:



$$\mathcal{L}^{\text{CLIP}}(\theta) = \mathbb{E} \left[\min \left\{ r_t(\theta) \cdot \hat{A}_t, \text{clip}(r_t(\theta); 1-\varepsilon, 1+\varepsilon) \cdot \hat{A}_t \right\} \right]$$

где ε — гиперпараметр (обычно 0.1–0.2).

Разберём два случая:

- $A_t > 0$: действие хорошее, хотим увеличить r_t . Если $r_t > 1 + \varepsilon$ — $\min$ выбирает clip , градиент **обнуляется**.
- $A_t < 0$: действие плохое, хотим уменьшить r_t . Если $r_t < 1 - \varepsilon$ — снова clip , обновления **нет**.

PPO-Clip: график



Вывод: PPO никогда не вознаграждает политику за то, что она слишком сильно отклонилась от предыдущей — ни в хорошую, ни в плохую сторону.

Алгоритм PPO

- 1 Собрать N траекторий с текущей политикой $\pi_{\theta(k)}$

Алгоритм PPO

- 1 Собрать N траекторий с текущей политикой $\pi_{\theta(k)}$
- 2 Посчитать $\delta_t, \hat{A}_t$ для каждого шага

Алгоритм PPO

- 1 Собрать N траекторий с текущей политикой $\pi_{\theta(k)}$
- 2 Посчитать $\delta_t, \hat{A}_t$ для каждого шага
- 3 Несколько раз обновить θ, φ по одним и тем же данным:

$$\theta \leftarrow \theta + \alpha_{\theta} \nabla_{\theta} \mathcal{L}^{\text{CLIP}}(\theta)$$

$$\varphi \leftarrow \varphi - \alpha_{\varphi} \nabla_{\varphi} \mathcal{L}^{\text{MSE}}(\varphi)$$

RLHF (RL from Human Feedback)

LLM Post-Train


- ① **Pretrain.** LLM обучается на задачу Next Token Prediction на большом корпусе текстов. *Но как сделать из такой модель helpful assistant?*

LLM Post-Train

- ❶ **Pretrain.** LLM обучается на задачу Next Token Prediction на большом корпусе текстов. *Но как сделать из такой модель helpful assistant?*
- ❷ **SFT.** LLM дообучается на парах (запрос, ответ) и учится отвечать на вопросы (а также запоминает формат ответов). *Но как заставить модель отвечать более «корректно»?*

LLM Post-Train

- 1 **Pretrain.** LLM обучается на задачу Next Token Prediction на большом корпусе текстов. *Но как сделать из такой модель helpful assistant?*
- 2 **SFT.** LLM дообучается на парах (запрос, ответ) и учится отвечать на вопросы (а также запоминает формат ответов). *Но как заставить модель отвечать более «корректно»?*
- 3 **RLHF.** Обучаем модель на предпочтения пользователей. *Как?*



Постановка задачи

Итак, у нас есть предобученная модель π^{SFT} и датасет предпочтений (prompt, accepted_answer, rejected_answer).

① State.

Постановка задачи

Итак, у нас есть предобученная модель π^{SFT} и датасет предпочтений (prompt, accepted_answer, rejected_answer).

- ① **State.** Промпт + написанная часть ответа.
- ② **Action.**

Постановка задачи

Итак, у нас есть предобученная модель π^{SFT} и датасет предпочтений (prompt, accepted_answer, rejected_answer).

- ❶ **State.** Промпт + написанная часть ответа.
- ❷ **Action.** Очередной токен.
- ❸ **Reward.**

Постановка задачи

Итак, у нас есть предобученная модель π^{SFT} и датасет предпочтений (prompt, accepted_answer, rejected_answer).

- ① **State.** Промпт + написанная часть ответа.
- ② **Action.** Очередной токен.
- ③ **Reward.** Reward model.
- ④ **Policy.**

Постановка задачи

Итак, у нас есть предобученная модель π^{SFT} и датасет предпочтений (prompt, accepted_answer, rejected_answer).

- ① **State.** Промпт + написанная часть ответа.
- ② **Action.** Очередной токен.
- ③ **Reward.** Reward model.
- ④ **Policy.** Наша LLM π_θ

Постановка задачи

Итак, у нас есть предобученная модель π^{SFT} и датасет предпочтений (prompt, accepted_answer, rejected_answer).

- ① **State.** Промпт + написанная часть ответа.
- ② **Action.** Очередной токен.
- ③ **Reward.** Reward model. *Как обучить?*
- ④ **Policy.** Наша LLM π_θ

Постановка задачи

Итак, у нас есть предобученная модель π^{SFT} и датасет предпочтений (prompt, accepted_answer, rejected_answer).

- ① **State.** Промпт + написанная часть ответа.
- ② **Action.** Очередной токен.
- ③ **Reward.** Reward model. *Как обучить?*
- ④ **Policy.** Наша LLM π_θ

Пусть $RM_\psi(x, y)$ — модель регрессии (чем больше число — тем лучше y).

Постановка задачи

Итак, у нас есть предобученная модель π^{SFT} и датасет предпочтений (prompt, accepted_answer, rejected_answer).

- 1 **State.** Промпт + написанная часть ответа.
- 2 **Action.** Очередной токен.
- 3 **Reward.** Reward model. *Как обучить?*
- 4 **Policy.** Наша LLM π_θ

Пусть $RM_\psi(x, y)$ — модель регрессии (чем больше число — тем лучше y).
 $\mathbb{P}(y_1 \succ y_2 | x) =$ — вероятность предпочтения.

Постановка задачи

Итак, у нас есть предобученная модель π^{SFT} и датасет предпочтений (prompt, accepted_answer, rejected_answer).

- 1 **State.** Промпт + написанная часть ответа.
- 2 **Action.** Очередной токен.
- 3 **Reward.** Reward model. *Как обучить?*
- 4 **Policy.** Наша LLM π_θ

Пусть $RM_\psi(x, y)$ — модель регрессии (чем больше число — тем лучше y).
 $\mathbb{P}(y_1 \succ y_2 | x) = \sigma(RM_\psi(x, y_1) - RM_\psi(x, y_2))$ — вероятность предпочтения.

Постановка задачи

Итак, у нас есть предобученная модель π^{SFT} и датасет предпочтений (prompt, accepted_answer, rejected_answer).

- 1 **State.** Промпт + написанная часть ответа.
- 2 **Action.** Очередной токен.
- 3 **Reward.** Reward model. *Как обучить?*
- 4 **Policy.** Наша LLM π_θ

Пусть $RM_\psi(x, y)$ — модель регрессии (чем больше число — тем лучше y).
 $\mathbb{P}(y_1 \succ y_2 | x) = \sigma(RM_\psi(x, y_1) - RM_\psi(x, y_2))$ — вероятность предпочтения.

Такой подход называется Bradley-Terry Framework.

Постановка задачи

Итак, у нас есть предобученная модель π^{SFT} и датасет предпочтений (prompt, accepted_answer, rejected_answer).

- 1 **State.** Промпт + написанная часть ответа.
- 2 **Action.** Очередной токен.
- 3 **Reward.** Reward model. *Как обучить?*
- 4 **Policy.** Наша LLM π_θ

Пусть $RM_\psi(x, y)$ — модель регрессии (чем больше число — тем лучше y).

$\mathbb{P}(y_1 \succ y_2 | x) = \sigma(RM_\psi(x, y_1) - RM_\psi(x, y_2))$ — вероятность предпочтения.

Такой подход называется Bradley-Terry Framework. (для RM_ψ можно взять backbone π^{SFT}).

Постановка задачи

Итак, у нас есть предобученная модель π^{SFT} и датасет предпочтений (prompt, accepted_answer, rejected_answer).

- 1 **State.** Промпт + написанная часть ответа.
- 2 **Action.** Очередной токен.
- 3 **Reward.** Reward model.
- 4 **Policy.** Наша LLM π_θ

Теперь можно применять PPO... Или нет?

Постановка задачи

Итак, у нас есть предобученная модель π^{SFT} и датасет предпочтений (prompt, accepted_answer, rejected_answer).

- 1 **State.** Промпт + написанная часть ответа.
- 2 **Action.** Очередной токен.
- 3 **Reward.** Reward model.
- 4 **Policy.** Наша LLM π_θ

Теперь можно применять PPO... Или нет? Мы не хотим, чтобы итоговая π^{RLHF} сильно отличалась от π^{SFT} . *Как это контролировать?*

KL-дивергенция

Пусть мы имеем два дискретных распределения $\pi(\cdot|s_t)$ и $\pi^{SFT}(\cdot|s_t)$ — хотим насколько близко они между собой, ввести «метрику».

KL-дивергенция

Пусть мы имеем два дискретных распределения $\pi(\cdot|s_t)$ и $\pi^{SFT}(\cdot|s_t)$ — хотим насколько близко они между собой, ввести «метрику». Давайте рассмотрим:

$$D_{KL}(\pi(\cdot|s_t) \parallel \pi^{SFT}(\cdot|s_t)) = \sum_a \pi(a|s_t) \log \frac{\pi(a|s_t)}{\pi^{SFT}(a|s_t)} \geq 0$$

KL-дивергенция

Пусть мы имеем два дискретных распределения $\pi(\cdot|s_t)$ и $\pi^{SFT}(\cdot|s_t)$ — хотим насколько близко они между собой, ввести «метрику». Давайте рассмотрим:

$$D_{KL}(\pi(\cdot|s_t) \parallel \pi^{SFT}(\cdot|s_t)) = \sum_a \pi(a|s_t) \log \frac{\pi(a|s_t)}{\pi^{SFT}(a|s_t)} \geq 0$$

Почему это не метрика?

KL-дивергенция

Пусть мы имеем два дискретных распределения $\pi(\cdot|s_t)$ и $\pi^{SFT}(\cdot|s_t)$ — хотим насколько близко они между собой, ввести «метрику». Давайте рассмотрим:

$$D_{KL}(\pi(\cdot|s_t) \parallel \pi^{SFT}(\cdot|s_t)) = \sum_a \pi(a|s_t) \log \frac{\pi(a|s_t)}{\pi^{SFT}(a|s_t)} \geq 0$$

Почему это не метрика? Например, она не симметричная.

KL-дивергенция

Пусть мы имеем два дискретных распределения $\pi(\cdot|s_t)$ и $\pi^{SFT}(\cdot|s_t)$ — хотим насколько близко они между собой, ввести «метрику». Давайте рассмотрим:

$$D_{KL}(\pi(\cdot|s_t) \parallel \pi^{SFT}(\cdot|s_t)) = \sum_a \pi(a|s_t) \log \frac{\pi(a|s_t)}{\pi^{SFT}(a|s_t)} \geq 0$$

Почему это не метрика? Например, она не симметричная.

Тогда давайте добавим в наш reward регуляризационный член:

$$RM_\psi(y|x) - \beta D_{KL}(\pi(\cdot|s_t) \parallel \pi^{SFT}(\cdot|s_t)).$$

Пайплан обучения

Инициализируем модели $\pi_{\theta(0)}$, $V_{\varphi(0)}$ из backbone π^{SFT} (можно прям использовать один и тот же backbone для обеих моделей).

Пайплан обучения

Инициализируем модели $\pi_{\theta(0)}$, $V_{\varphi(0)}$ из backbone π^{SFT} (можно прям использовать один и тот же backbone для обеих моделей).

- 1 Выбираем промпт $\vec{q}$.

Пайплан обучения

Инициализируем модели $\pi_{\theta(0)}$, $V_{\varphi(0)}$ из backbone π^{SFT} (можно прям использовать один и тот же backbone для обеих моделей).

- 1 Выбираем промпт $\vec{q}$.
- 2 Генерируем последовательность $\vec{o}$ ответа из $\pi_{\theta(k)}$.

Пайплан обучения

Инициализируем модели $\pi_{\theta(0)}$, $V_{\varphi(0)}$ из backbone π^{SFT} (можно прям использовать один и тот же backbone для обеих моделей).

- 1 Выбираем промпт $\vec{q}$.
- 2 Генерируем последовательность $\vec{o}$ ответа из $\pi_{\theta(k)}$.
- 3 Параллельно подсчитываем $V_{\varphi(k)}(o_t)$.

r_t для всех шагов кроме последнего определяется как $-\beta D_{KL}(\dots)$, а для последнего $RM(\vec{o}|\vec{q}) - \beta D_{KL}(\dots)$.

Пайплан обучения

Инициализируем модели $\pi_{\theta(0)}$, $V_{\varphi(0)}$ из backbone π^{SFT} (можно прям использовать один и тот же backbone для обеих моделей).

① Выбираем промпт $\vec{q}$.

② Генерируем последовательность $\vec{o}$ ответа из $\pi_{\theta(k)}$.

③ Параллельно подсчитываем $V_{\varphi(k)}(o_t)$.

r_t для всех шагов кроме последнего определяется как $-\beta D_{KL}(\dots)$, а для последнего $RM(\vec{o}|\vec{q}) - \beta D_{KL}(\dots)$.

④ Далее считаются δ_t и, соответственно, $\hat{A}_t := \delta_t + \gamma \lambda \hat{A}_{t+1}$

Пайплан обучения

Инициализируем модели $\pi_{\theta(0)}$, $V_{\varphi(0)}$ из backbone π^{SFT} (можно прям использовать один и тот же backbone для обеих моделей).

- 1 Выбираем промпт $\vec{q}$.
- 2 Генерируем последовательность $\vec{o}$ ответа из $\pi_{\theta(k)}$.
- 3 Параллельно подсчитываем $V_{\varphi(k)}(o_t)$.
 r_t для всех шагов кроме последнего определяется как $-\beta D_{KL}(\dots)$, а для последнего $RM(\vec{o}|\vec{q}) - \beta D_{KL}(\dots)$.
- 4 Далее считаются δ_t и, соответственно, $\hat{A}_t := \delta_t + \gamma \lambda \hat{A}_{t+1}$
- 5 Далее оптимизируется $\mathcal{L}^{CLIP+VF+S}(\theta^{(k)}, \varphi^{(k)})$.

Пайплан обучения

Инициализируем модели $\pi_{\theta(0)}$, $V_{\varphi(0)}$ из backbone π^{SFT} (можно прям использовать один и тот же backbone для обеих моделей).

- 1 Выбираем промпт $\vec{q}$.
- 2 Генерируем последовательность $\vec{o}$ ответа из $\pi_{\theta(k)}$.
- 3 Параллельно подсчитываем $V_{\varphi(k)}(o_t)$.
 r_t для всех шагов кроме последнего определяется как $-\beta D_{KL}(\dots)$, а для последнего $RM(\vec{o}|\vec{q}) - \beta D_{KL}(\dots)$.
- 4 Далее считаются δ_t и, соответственно, $\hat{A}_t := \delta_t + \gamma \lambda \hat{A}_{t+1}$
- 5 Далее оптимизируется $\mathcal{L}^{CLIP+VF+S}(\theta^{(k)}, \varphi^{(k)})$. *Что? Да!*

Лосс-функция

$$\mathcal{L}^{CLIP+VF+S}(\theta, \varphi) := \mathbb{E}_t[\mathcal{L}_t^{CLIP}(\theta) - c_1 \mathcal{L}_t^{VF}(\varphi) + c_2 S[\pi_{\theta(k)}](s_t)]$$

Так как мы используем общий backbone для π_θ , V_φ , то и лосс мы собрали общий.

Лосс-функция

$$\mathcal{L}^{CLIP+VF+S}(\theta, \varphi) := \mathbb{E}_t[\mathcal{L}_t^{CLIP}(\theta) - c_1 \mathcal{L}_t^{VF}(\varphi) + c_2 S[\pi_{\theta(k)}](s_t)]$$

Так как мы используем общий backbone для π_θ , V_φ , то и лосс мы собрали общий.

Лосс-функция

$$\mathcal{L}^{CLIP+VF+S}(\theta, \varphi) := \mathbb{E}_t[\mathcal{L}_t^{CLIP}(\theta) - c_1 \mathcal{L}_t^{VF}(\varphi) + c_2 S[\pi_{\theta(k)}](s_t)]$$

Так как мы используем общий backbone для π_θ , V_φ , то и лосс мы собрали общий.

Также зачастую добавляется **entropy bonus** $S[\pi](s) := - \sum_a \pi(a|s) \log \pi(a|s)$ — энтропия Шеннона (таким образом мы поощряем «разнообразие» модели).

RLVR (RL with Verifiable Rewards)

GRPO: групповая оценка

Идея: попробуем заменить модель критик просто оценив baseline семплированием.

GRPO: групповая оценка

Идея: попробуем заменить модель критик просто оценив baseline семплированием.

Для каждого промпта q семплируем **группу** из G ответов от старой политики:

$$o_1, o_2, \dots, o_G \sim \pi_{\theta^{(k)}}(\cdot \mid q)$$

GRPO: групповая оценка

Идея: попробуем заменить модель критик просто оценив baseline семплированием.

Для каждого промпта q семплируем **группу** из G ответов от старой политики:

$$o_1, o_2, \dots, o_G \sim \pi_{\theta^{(k)}}(\cdot \mid q)$$

Для каждого ответа получаем reward r_i . Тогда **advantage**:

$$\hat{A}_i = \frac{r_i - \mu_G}{\sigma_G}, \quad \mu_G = \frac{1}{G} \sum_{j=1}^G r_j, \quad \sigma_G = \sqrt{\frac{1}{G} \sum_{j=1}^G (r_j - \mu_G)^2}$$

GRPO: целевая функция


GRPO Objective

$$\mathcal{L}^{\text{GRPO}}(\theta) = \mathbb{E}_{q, \{o_i\}} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \mathcal{L}_t^{\text{CLIP}}(\theta) - \beta D_{KL}(\pi_{\theta} \parallel \pi^{\text{ref}}) \right]$$

Постановка проблемы

Verifiable Reward — пусть у нас есть задача, которую мы можем объективно оценить (e.g., математика, алгозадачи).

Хочется научить модель *мыслить* и обосновывать свой ход решения.



DeepSeek-R1-Zero

Попробуем обойтись без SFT и сразу применить GRPO к базовой модели

DeepSeek-R1-Zero

Попробуем обойтись без SFT и сразу применить GRPO к базовой модели

Попробовали. Модель действительно научилась решать задачи и даже перепроверять своё решение. Но...

Question: If $a > 1$, then the sum of the real solutions of $\sqrt{a - \sqrt{a + x}} = x$ is equal to

Response: <think>

To solve the equation $\sqrt{a - \sqrt{a + x}} = x$, let's start by squaring both ...

$$(\sqrt{a - \sqrt{a + x}})^2 = x^2 \implies a - \sqrt{a + x} = x^2.$$

Rearrange to isolate the inner square root term:

$$(a - x^2)^2 = a + x \implies a^2 - 2ax^2 + (x^2)^2 = a + x \implies x^4 - 2ax^2 - x + (a^2 - a) = 0$$

...

Wait, wait. Wait. That's an aha moment I can flag here.

Let's reevaluate this step-by-step to identify if the correct sum can be ...

We started with the equation:

$$\sqrt{a - \sqrt{a + x}} = x$$

First, let's square both sides:

$$a - \sqrt{a + x} = x^2 \implies \sqrt{a + x} = a - x^2$$

Next, I could square both sides again, treating the equation: ...

DeepSeek-R1-Zero

Попробуем обойтись без SFT и сразу применить GRPO к базовой модели

Попробовали. Модель действительно научилась решать задачи и даже перепроверять своё решение. Но... Ответы были poor-formated и часто содержали несколько языков (то есть reasoning traces были тяжело читаемы).

Question: If $a > 1$, then the sum of the real solutions of $\sqrt{a - \sqrt{a + x}} = x$ is equal to

Response: <think>

To solve the equation $\sqrt{a - \sqrt{a + x}} = x$, let's start by squaring both ...

$$(\sqrt{a - \sqrt{a + x}})^2 = x^2 \implies a - \sqrt{a + x} = x^2.$$

Rearrange to isolate the inner square root term:

$$(a - x^2)^2 = a + x \implies a^2 - 2ax^2 + (x^2)^2 = a + x \implies x^4 - 2ax^2 - x + (a^2 - a) = 0$$

...

Wait, wait. Wait. That's an aha moment I can flag here.

Let's reevaluate this step-by-step to identify if the correct sum can be ...

We started with the equation:

$$\sqrt{a - \sqrt{a + x}} = x$$

First, let's square both sides:

$$a - \sqrt{a + x} = x^2 \implies \sqrt{a + x} = a - x^2$$

Next, I could square both sides again, treating the equation: ...

Cold-Start SFT

Проблема: базовая модель не умеет оформлять мысли в виде рассуждений. Если сразу дать ей GRPO, она находит правильные ответы, но «думает» хаотично.

Cold-Start SFT


Проблема: базовая модель не умеет оформлять мысли в виде рассуждений. Если сразу дать ей GRPO, она находит правильные ответы, но «думает» хаотично.

Решение: несколько тысяч вручную отобранных примеров с reasoning traces:

```
<think> шаг 1 ... шаг N </think> <answer> ответ </answer>
```

GRPO


Теперь запускаем GRPO. Reward-модели нет — только два типа наград:



GRPO

Теперь запускаем GRPO. Reward-модели нет — только два типа наград:


- **Correctness reward:** ответ совпадает с ground truth? +1 или 0.



GRPO

Теперь запускаем GRPO. Reward-модели нет — только два типа наград:

- **Correctness reward:** ответ совпадает с ground truth? +1 или 0.
- **Format reward:** формат `<think>...</think>` + language consistency



Rejection Sampling SFT

После первого GRPO модель хорошо рассуждает, но всё ещё бывает нестабильна по стилю.

Rejection Sampling SFT

После первого GRPO модель хорошо рассуждает, но всё ещё бывает нестабильна по стилю.

Идея: использовать саму модель для генерации обучающих данных.

Rejection Sampling SFT

После первого GRPO модель хорошо рассуждает, но всё ещё бывает нестабильна по стилю.

Идея: использовать саму модель для генерации обучающих данных.

- 1 Генерируем $\sim 800k$ ответов модели на новые задачи.

Rejection Sampling SFT

После первого GRPO модель хорошо рассуждает, но всё ещё бывает нестабильна по стилю.

Идея: использовать саму модель для генерации обучающих данных.

- 1 Генерируем $\sim 800k$ ответов модели на новые задачи.
- 2 Отбрасываем неверные (верификатором) и стилистически плохие (LLM-as-Judge).

Rejection Sampling SFT

После первого GRPO модель хорошо рассуждает, но всё ещё бывает нестабильна по стилю.

Идея: использовать саму модель для генерации обучающих данных.

- 1 Генерируем $\sim 800k$ ответов модели на новые задачи.
- 2 Отбрасываем неверные (верификатором) и стилистически плохие (LLM-as-Judge).
- 3 Докидываем данные из non-reasoning задач.

Rejection Sampling SFT

После первого GRPO модель хорошо рассуждает, но всё ещё бывает нестабильна по стилю.

Идея: использовать саму модель для генерации обучающих данных.

- 1 Генерируем $\sim 800k$ ответов модели на новые задачи.
- 2 Отбрасываем неверные (верификатором) и стилистически плохие (LLM-as-Judge).
- 3 Докидываем данные из non-reasoning задач.
- 4 SFT на всём этом.

Зачем? RL хорош для поиска нового поведения, но неэффективен для его закрепления. SFT на собственных хороших выходах — дешёвый способ дистиллировать найденное RL поведение обратно в веса.

GRPO для alignment

Теперь модель умеет рассуждать, но обучалась только на math/code задачах. Нужно сделать её *helpful assistant*.

GRPO для alignment

Теперь модель умеет рассуждать, но обучалась только на math/code задачах. Нужно сделать её *helpful assistant*.

Запускаем GRPO ещё раз, но уже:

GRPO для alignment

Теперь модель умеет рассуждать, но обучалась только на math/code задачах. Нужно сделать её *helpful assistant*.

Запускаем GRPO ещё раз, но уже:

- На широком спектре задач (не только верифицируемых).

GRPO для alignment

Теперь модель умеет рассуждать, но обучалась только на math/code задачах. Нужно сделать её *helpful assistant*.

Запускаем GRPO ещё раз, но уже:

- На широком спектре задач (не только верифицируемых).
- С general reward model (обученной на предпочтениях людей).

GRPO для alignment

Теперь модель умеет рассуждать, но обучалась только на math/code задачах. Нужно сделать её *helpful assistant*.


Запускаем GRPO ещё раз, но уже:

- На широком спектре задач (не только верифицируемых).
- С general reward model (обученной на предпочтениях людей).
- С дополнительными safety-ограничениями.

Итоговый пайплайн



DeepSeek-R1 Training Pipeline



Действительно ли
RLVR учит рассуждать?


Постановка проблемы

До этого мы говорили, что модель *учится* рассуждать с помощью RLVR. Но насколько действительно *новые* стратегии модель выучивает?

Постановка проблемы

До этого мы говорили, что модель *учится* рассуждать с помощью RLVR. Но насколько действительно *новые* стратегии модель выучивает?

Судя по всему, более корректно говорить о том, что RLVR просто перераспределяет вероятности так, чтобы корректный reasoning trace стал более вероятным.




pass@k

Если рассматривать *pass@1* метрику (то есть вероятность правильно ответить на задачу у моделей), то RLVR-model действительно показывает себя лучше base.

pass@k

Однако если рассматривать $pass@k$ для больших k (то есть вероятность решить задачу за k попыток), то мы увидим, что зачастую модели не отличаются (или RLVR проигрывает).



pass@k

Более того, RLVR уменьшает изначальный coverage решаемых задач base модели.

Base	SimpleRLZoo	AIME24	MATH500
✓	✓	63.3%	92.4%
✓	×	13.3%	3.6%
×	✓	0.0%	1.0%
×	×	23.3%	3.0%

Все алгоритмы одинаково далеки от потолка


Рассмотрим sampling efficiency gap:

$$\Delta_{SE} = \underbrace{\text{pass@1}_{\text{RL}}}_{\text{достигнутое}} - \underbrace{\text{pass@256}_{\text{base}}}_{\text{потолок}}$$

Все алгоритмы одинаково далеки от потолка


Рассмотрим sampling efficiency gap:

$$\Delta_{SE} = \underbrace{\text{pass@1}_{\text{RL}}}_{\text{достигнутое}} - \underbrace{\text{pass@256}_{\text{base}}}_{\text{потолок}}$$



RLVR vs Дистилляция

Заметим, что тот же паттерн не повторяется при дистилляции, то есть reasoning'у действительно можно научиться у другой модели.



Спасибо за внимание!

Леонтьев Михаил • Хакатон ИТМО

Telegram



https://t.me/michlea_tg

Фидбек+материалы



<https://forms.gle/isNG7V2e6QWKTGTW8>